COMPARAÇÃO ENTRE *k*-NN E SVM NA CLASSIFICAÇÃO DE DESEMPENHO ACADÊMICO E DE ENTREGAS URBANAS

Hilário Oliveira Marques Filho[1], **Ryan Charles Lima Sousa**[1], **Luca Aureo Teixeira**[1]

[1]Curso de Ciência da Computação (5º bloco) – Disciplina de Inteligência Artificial
Universidade Estadual do Piauí (UESPI) – Piauí – Brasil

hilariofilho2005@aluno.uespi.br, ryansousa@aluno.uespi.br,
lucateixeira@aluno.uespi.br

Resumo. Este trabalho compara dois algoritmos de classificação supervisionada, *k*-vizinhos mais próximos (*k*-NN) e máquinas de vetores de suporte (SVM), em dois conjuntos de dados tabulares fornecidos pelo professor da disciplina, cada um com 2.000 registros: um de desempenho acadêmico (aprovação de alunos) e um de entregas urbanas (entrega no prazo). Foram variados o número de vizinhos e a medida de distância no *k*-NN e os parâmetros C e γ (kernels linear e RBF) no SVM, com padronização dos atributos e divisão estratificada 80/20. No conjunto de entregas, a escolha dos parâmetros foi feita por validação cruzada estratificada de cinco partições apenas no treino; no teste de 400 entregas, *k*-NN (*k*=51, Manhattan) e SVM RBF (C=10, γ=0,01) obtiveram acurácia de 82,25 % e 82,50 %, uma diferença de um único acerto, mas com perfis de erro distintos. No conjunto acadêmico, os melhores modelos alcançaram acurácia de 67,5 % (*k*-NN, *k*=3) e 71,0 % (SVM linear, C=0,1), perto dos 67 % de um classificador que sempre prevê a classe majoritária, e todos tiveram dificuldade em identificar alunos aprovados (recall da classe entre 0,35 e 0,45). Conclui-se que nenhum dos algoritmos se mostrou claramente superior e que a escolha depende do custo atribuído a cada tipo de erro.

Palavras-chave: aprendizado de máquina; classificação; *k*-NN; SVM; desempenho acadêmico; entregas urbanas.

Abstract. This work compares two supervised classifiers, *k*-nearest neighbors (*k*-NN) and support vector machines (SVM), on two tabular datasets provided by the course instructor, each with 2,000 records: academic performance (student approval) and urban deliveries (on--time delivery). We varied the number of neighbors and the distance measure for *k*-NN, and the parameters C and γ (linear and RBF kernels) for SVM, using feature standardization and a stratified 80/20 split. For the delivery dataset, hyperparameters were selected by five-fold stratified cross-validation on the training set only; on the 400-delivery test set, *k*-NN (*k*=51, Manhattan) and RBF SVM (C=10, γ=0.01) reached accuracies of 82.25% and 82.50%, a difference of a single correct prediction, with different error profiles. For the academic dataset, the best models reached 67.5% accuracy (*k*-NN, *k*=3) and 71.0% (linear SVM, C=0.1), close to the 67% of a majority-class baseline, and all models struggled to identify approved students (class recall between 0.35 and 0.45). Neither algorithm was clearly superior; the choice depends on the cost assigned to each error type.

Keywords: machine learning; classification; *k*-NN; SVM; academic performance; urban deliveries.

1. INTRODUÇÃO

A classificação supervisionada consiste em treinar um modelo com exemplos cujas classes são conhecidas para prever a classe de registros novos (WESSEL, 2026). Entre os algoritmos

mais usados para dados tabulares estão o *k*-vizinhos mais próximos (*k*-NN), que classifica um registro pela classe majoritária de seus vizinhos mais próximos (COVER; HART, 1967), e a máquina de vetores de suporte (SVM), que busca a fronteira de separação de maior margem entre as classes (CORTES; VAPNIK, 1995). Ambos são sensíveis à escala dos atributos e dependem de hiperparâmetros cuja escolha altera o resultado de forma relevante (SILVA; PERES; BOSCARIOLI, 2016).

Este trabalho foi desenvolvido na disciplina de Inteligência Artificial do curso de Ciência da Computação da Universidade Estadual do Piauí (UESPI). O objetivo é comparar *k*-NN e SVM em dois problemas de classificação binária com conjuntos de dados fornecidos pelo professor: (i) prever se um aluno é aprovado, a partir de hábitos de estudo e condições pessoais; e (ii) prever se uma entrega urbana chegará no prazo, a partir de características da entrega, do trânsito e da operação. Para cada algoritmo foram avaliados o número de vizinhos e a medida de distância (*k*-NN) e os parâmetros C e γ e o tipo de kernel (SVM).

As contribuições são: (i) uma comparação dos dois algoritmos sob um mesmo pré-processamento e uma mesma divisão de dados em cada problema; (ii) a análise da sensibilidade dos modelos aos hiperparâmetros, incluindo configurações que degeneram para a previsão da classe majoritária; e (iii) uma discussão explícita de limitações metodológicas, em especial a diferença entre os dois problemas quanto ao uso do conjunto de teste na escolha dos parâmetros.

O artigo está organizado assim: a Seção 2 apresenta trabalhos relacionados; a Seção 3 descreve a metodologia; a Seção 4 apresenta e discute os resultados; e a Seção 5 traz as conclusões e trabalhos futuros.

2. TRABALHOS RELACIONADOS

Ayres, Brito e Souza ([2019?]) propõem a detecção de URLs maliciosas direcionadas a usuários brasileiros com aprendizado de máquina, usando mais de 110 características e comparando Naive Bayes, *k*-NN, SVM e árvore de decisão J48 com validação cruzada de dez partições. O *k*-NN obteve o melhor resultado (acurácia de 96,02 %) e o SVM chegou a 94,61 % com C=50. Os autores ajustaram o parâmetro C do SVM e observaram que aumentá-lo elevou a acurácia e a precisão nessa base, o que motiva a variação sistemática de parâmetros feita aqui, embora o efeito de C dependa do conjunto de dados.

Wessel (2026) compara Regressão Logística, *k*-NN (sete vizinhos), SVM com kernel RBF, *Random Forest* e *Gradient Boosting* na predição de doença cardíaca (base Cleveland, 303

registros), com padronização ajustada apenas no treino, validação cruzada de dez partições e métricas de acurácia, precisão, revocação, F1 e AUC. A acurácia de validação cruzada ficou entre 77,18 % e 83,45 %, com diferenças pequenas entre os quatro melhores modelos, e o autor destaca a revocação da classe positiva em contextos em que o falso negativo é o erro mais custoso. Dessa referência adotamos o cuidado de ajustar o pré-processamento somente com dados de treino e de analisar métricas por classe, e não apenas a acurácia.

Diferentemente desses trabalhos, os conjuntos aqui são de domínios educacional e logístico, têm 2.000 registros e foram fornecidos pelo professor.

3. METODOLOGIA

A pesquisa é experimental, de natureza quantitativa. Todos os experimentos foram feitos em Python, com a biblioteca *scikit-learn* (PEDREGOSA et al., 2011), e a semente aleatória foi fixada em 42 em todas as divisões.

3.1. Conjuntos de dados

Os dois conjuntos foram fornecidos pelo professor e contêm 2.000 registros, sem valores ausentes. O conjunto de **desempenho acadêmico** tem 10 atributos de entrada (Tabela 1) e a variável-alvo `aprovado`, com 1.338 alunos não aprovados (66,9 %) e 662 aprovados (33,1 %). O conjunto de **entregas urbanas** tem 10 atributos de entrada e a variável-alvo `entrega_no_prazo`, com 960 entregas atrasadas (48,0 %) e 1.040 no prazo (52,0 %); sem registros duplicados. Assim, o problema acadêmico é desbalanceado, e o de entregas é praticamente balanceado.

Tabela 1. Atributos de entrada dos dois conjuntos de dados.

Desempenho acadêmico	**Entregas urbanas**
idade; horas de estudo por semana; frequência (%); atividades entregues (%); horas de sono; trabalha (0/1); deslocamento (min); internet estável (0/1); nota anterior; participação em aula	distância (km); nível de trânsito; intensidade de chuva; horário de pico (0/1); entregador fixo (0/1); tempo de preparação do pedido (min); prazo prometido (min); paradas adicionais; experiência do entregador (anos); tipo de veículo (categórico: 0, 1 e 2)
Alvo: aprovado (0/1)	**Alvo:** entrega no prazo (0/1)

Fonte: elaborado pelos autores com base nos conjuntos fornecidos pelo professor.

3.2. Divisão e pré-processamento

Em ambos os problemas, os dados foram divididos de forma estratificada em 80 % para treino (1.600 registros) e 20 % para teste (400 registros), preservando a proporção das classes: no teste acadêmico, 268 não aprovados e 132 aprovados; no teste de entregas, 192 atrasadas e 208 no prazo.

Como *k*-NN e SVM dependem de distâncias, os atributos numéricos foram padronizados por z-score, $z = (x - \mu_{\text{treino}})/\sigma_{\text{treino}}$, com média e desvio padrão calculados somente no treino, para evitar vazamento de informação do teste (SILVA; PERES; BOSCARIOLI, 2016; WESSEL, 2026). No conjunto acadêmico, todos os 10 atributos foram padronizados. No de entregas, os sete atributos numéricos foram padronizados, os dois binários foram mantidos e `tipo_veiculo`, cujos códigos não têm ordem natural, foi codificado por *one-hot*, resultando em 12 atributos. No conjunto de entregas, esse pré-processamento foi reajustado dentro de cada partição da validação cruzada.

3.3. Algoritmos

***k*-NN.** Cada registro é classificado pela classe majoritária entre seus k vizinhos mais próximos do treino, com votos de peso uniforme. A distância de Minkowski de ordem p é $d_p(\mathbf{x}, \mathbf{v}) = \left(\sum_j |x_j - v_j|^p\right)^{1/p}$, que resulta na distância de Manhattan ($p = 1$) e na Euclidiana ($p = 2$); a de Chebyshev corresponde ao máximo das diferenças absolutas. Foram testados $k \in \{1, 3, 5, 7, 11, 15, 25, 51\}$. Na base acadêmica foram comparadas quatro distâncias (Euclidiana, Manhattan, Minkowski com $p = 3$ e Chebyshev); na de entregas, Euclidiana e Manhattan.

SVM. O SVM busca o hiperplano de maior margem, tolerando violações penalizadas pelo parâmetro C; exemplos que definem a fronteira são os vetores de suporte (CORTES; VAPNIK, 1995). Com o kernel RBF, $K(\mathbf{x}, \mathbf{v}) = \exp(-\gamma\|\mathbf{x} - \mathbf{v}\|^2)$, o parâmetro γ controla o alcance da influência de cada exemplo: valores altos geram fronteiras muito flexíveis, e valores baixos, fronteiras mais suaves. Na base acadêmica foram avaliados o kernel linear, com C entre 0,001 e 100 em potências de 10 (0,001; 0,01; 0,1; 1; 10; 100), e o RBF, em uma grade de 25 combinações de $C \in \{0{,}01;\ 0{,}1;\ 1;\ 10;\ 100\}$ e $\gamma \in \{0{,}001;\ 0{,}01;\ 0{,}1;\ 1;\ 10\}$. Na base de entregas foi avaliado somente o kernel RBF, com a mesma grade de 25 combinações.

3.4. Protocolo de seleção e avaliação

As métricas são acurácia, precisão, revocação (*recall*) e F1, com média macro (mesmo peso para as duas classes), além de AUC-ROC e *average precision* (AP) onde indicado. Como os dois

problemas foram conduzidos em momentos diferentes, **os protocolos de seleção de parâmetros diferem**, e isso afeta a interpretação:

- **Entregas urbanas:** os parâmetros foram escolhidos por validação cruzada estratificada de cinco partições *somente no treino*, com o maior F1 macro médio como critério. O conjunto de teste foi usado uma única vez, para a avaliação final.
- **Desempenho acadêmico:** os parâmetros foram escolhidos comparando as métricas *diretamente no conjunto de teste* (recall macro para o *k*-NN; F1 macro para o RBF; e acurácia e métricas macro para o C do SVM linear). Isso torna os resultados desse problema possivelmente otimistas, o que já era reconhecido nos próprios experimentos, e eles não são diretamente comparáveis aos de entregas.

4. RESULTADOS E DISCUSSÃO

4.1. Entregas urbanas: *k*-NN

Um *k*-NN inicial (*k*=5, Euclidiana) obteve acurácia média de 73,56 % (desvio 0,65 p.p.) na validação cruzada. A Tabela 2 mostra o F1 macro médio das 16 configurações. O desempenho cresce com k até cerca de 15 e depois se estabiliza (Figura 1). A melhor configuração foi k=51 com distância de Manhattan (acurácia de 77,44 %, F1 macro de 77,12 %), mas a Euclidiana com k=51 ficou praticamente igual (77,01 %), e o desvio padrão do F1 entre as partições (cerca de 2 a 3 p.p.) é maior que as diferenças entre as duas distâncias. Como 51 é o maior valor testado, não é possível afirmar que seja o ótimo; valores maiores não foram avaliados.

Tabela 2. Entregas urbanas: F1 macro médio do *k*-NN na validação cruzada (5 partições, treino).

k	1	3	5	7	11	15	25	51
Euclidiana	0,6875	0,7196	0,7348	0,7461	0,7509	0,7629	0,7566	0,7701
Manhattan	0,6856	0,7118	0,7328	0,7366	0,7470	0,7634	0,7631	**0,7712**

Fonte: elaborado pelos autores.

4.2. Entregas urbanas: SVM com kernel RBF

O SVM inicial (C=1, γ=0,1) teve acurácia média de 78,12 % (desvio 2,10 p.p.), com 843 vetores de suporte. Na grade completa (Figura 2), a melhor configuração foi C=10 e γ=0,01, com acurácia de 79,25 % e F1 macro de 79,19 %. Sete configurações ficaram entre 78,76 % e 79,19 % de F1 macro, de modo que a vencedora não se distingue estatisticamente das demais. O

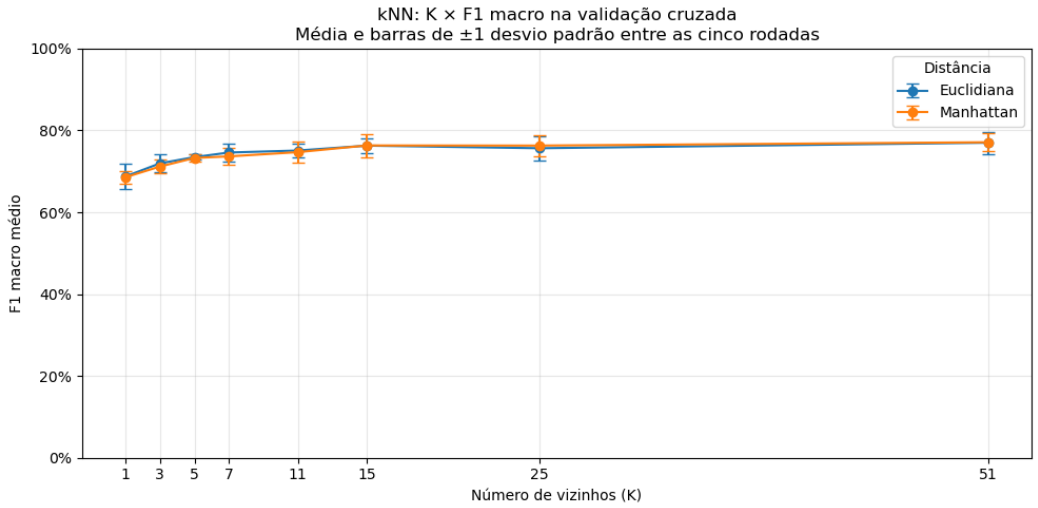


Figura 1. Entregas urbanas: F1 macro do k-NN em função de k (média e ± 1 desvio padrão).
Fonte: elaborada pelos autores.

comportamento nos extremos é relevante: com γ=10, todas as configurações caíram para cerca de 52 % de acurácia, valor igual à proporção da classe majoritária (52 %), e com C=0,01 (e com C=0,1 combinado a γ=0,001, 1 ou 10) o modelo praticamente só previu a classe majoritária (F1 macro de cerca de 34 %). Valores altos de C e γ não garantem melhora; os dois parâmetros devem ser ajustados em conjunto.

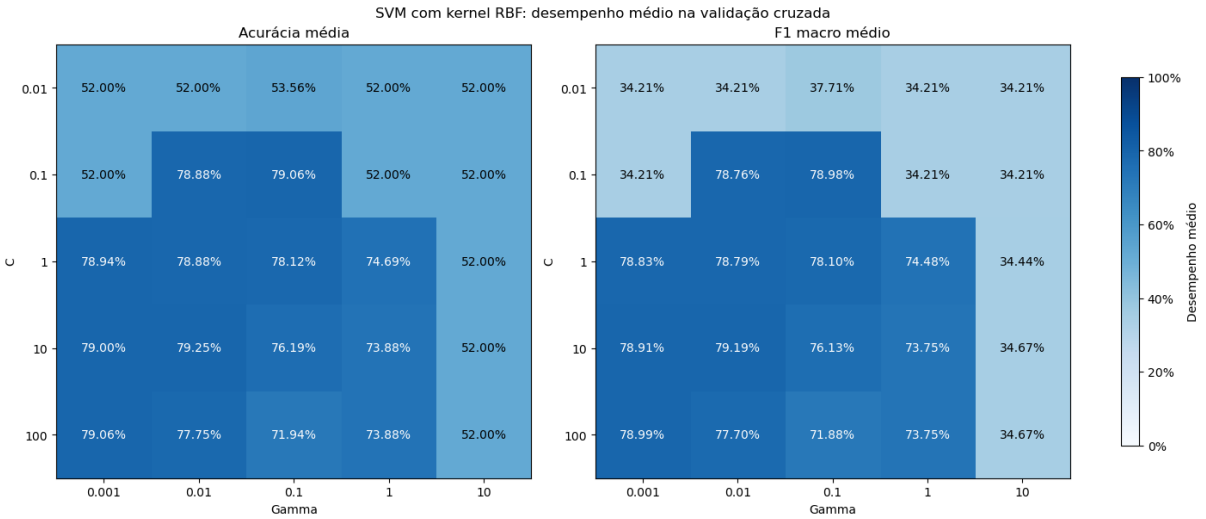


Figura 2. Entregas urbanas: acurácia média e F1 macro médio do SVM RBF na validação cruzada, por C e γ.
Fonte: elaborada pelos autores.

4.3. Entregas urbanas: avaliação final no teste

Os dois modelos selecionados foram ajustados nas 1.600 entregas de treino e avaliados nas 400 de teste (Tabela 3). A acurácia foi de 82,25 % (329 acertos) para o k-NN e 82,50 % (330 acertos)

para o SVM, uma diferença de um registro. Com 400 exemplos, o erro-padrão da acurácia é de aproximadamente 1,9 p.p., portanto essa diferença não permite afirmar que um algoritmo seja melhor que o outro. Ambos tiveram acurácia no teste superior à da validação cruzada (77 a 79 %); o notebook não investiga a causa, e as explicações plausíveis são o treino com mais dados (1.600 contra 1.280 por partição) e a variação amostral do teste.

Tabela 3. Entregas urbanas: desempenho no conjunto de teste (400 entregas).

Modelo	**Acurácia**	**Precisão macro**	**Recall macro**	**F1 macro**
k-NN (k=51, Manhattan)	82,25 %	82,35 %	82,11 %	82,17 %
SVM RBF (C=10, γ=0,01)	82,50 %	82,59 %	82,61 %	82,50 %

Fonte: elaborado pelos autores.

As matrizes de confusão (Figura 3) mostram perfis de erro diferentes com total de erros quase igual (71 para o k-NN e 70 para o SVM). O SVM identificou 164 dos 192 atrasos (85,42 %), contra 151 (78,65 %) do k-NN; em contrapartida, o k-NN identificou 178 das 208 entregas no prazo (85,58 %), contra 166 (79,81 %) do SVM. Em termos operacionais, o SVM deixa passar menos atrasos (28 contra 41 previsões de "no prazo" que atrasaram), mas gera mais alertas falsos de atraso (42 contra 30). Qual erro é mais custoso depende da operação, e esses custos não foram definidos neste estudo.

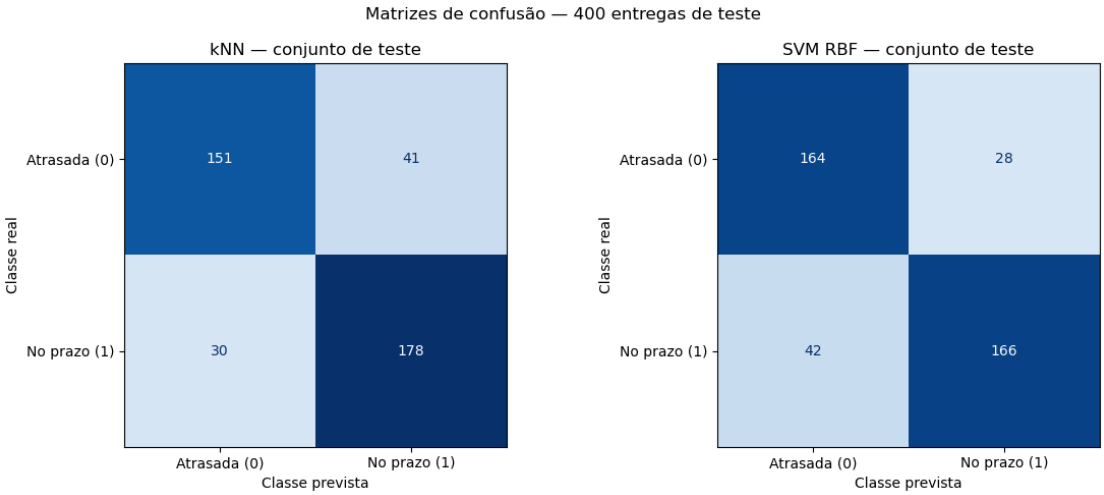


Figura 3. Entregas urbanas: matrizes de confusão no teste (linhas: classe real; colunas: classe prevista).
Fonte: elaborada pelos autores.

4.4. Desempenho acadêmico: *k*-NN

Nesta base, a classe majoritária (não aprovado) representa 67 % do teste, e um classificador que sempre a prevê atinge essa acurácia. Os resultados devem ser lidos nesse contexto. Com

padronização, k=3 e distância Euclidiana, o k-NN obteve acurácia de 67,5 %, F1 macro de 0,617 e recall macro de 0,613, com recall de 0,79 para "não aprovado" e de apenas 0,43 para "aprovado". A Tabela 4 e a Figura 4 mostram a variação com k: a maior acurácia (69,25 %) ocorre com k=51, mas com recall macro de apenas 0,578, possivelmente porque o modelo passa a favorecer a classe majoritária; k=3 foi escolhido por ter o maior recall macro (e o maior F1 macro) do teste. Como essa escolha foi feita no próprio teste, ela pode estar superestimada.

Tabela 4. Desempenho acadêmico: k-NN no conjunto de teste, por k (distância Euclidiana).

k	1	3	5	7	11	15	25	51
Acurácia	0,6175	**0,6750**	0,6725	0,6625	0,6800	0,6800	0,6750	0,6925
Recall macro	0,5665	**0,6133**	0,5999	0,5751	0,5959	0,5786	0,5710	0,5783
F1 macro	0,5667	**0,6167**	0,6034	0,5756	0,5987	0,5761	0,5667	0,5708

Fonte: elaborado pelos autores.

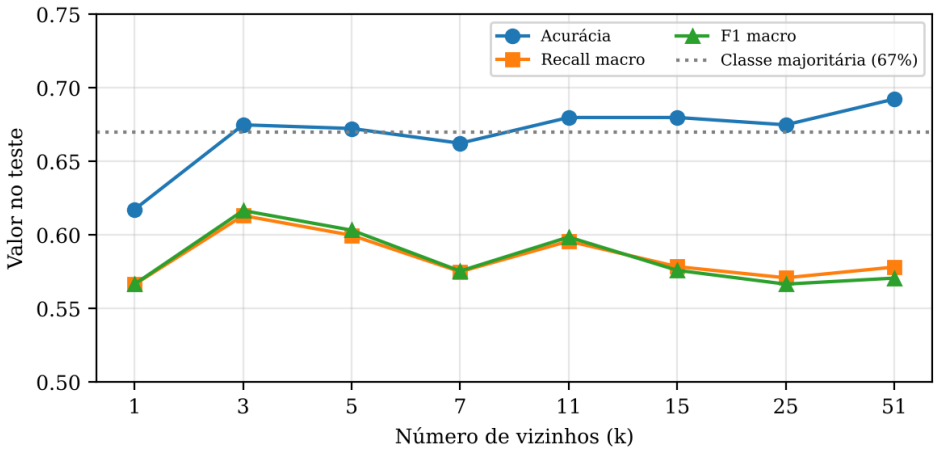


Figura 4. Desempenho acadêmico: métricas do k-NN no teste em função de k.
Fonte: elaborada pelos autores.

Três experimentos adicionais com k=3 (Tabela 5) mostram que (i) a padronização melhorou todas as métricas (acurácia de 65,0 % para 67,5 %); (ii) a distância Euclidiana superou Manhattan, Minkowski (p=3) e Chebyshev; e (iii) o PCA, mantendo 8 componentes (82,17 % da variância), piorou todas as métricas. Isso sugere que as informações descartadas pelos componentes de menor variância eram úteis para a classificação e que a redução de dimensionalidade não compensa neste conjunto. Cada comparação usa uma única divisão de teste e as diferenças de 1 a 3 p.p. estão dentro da variação esperada para 400 exemplos; elas são indícios, não conclusões firmes.

Tabela 5. Desempenho acadêmico: experimentos adicionais do k-NN (k=3, teste).

Experimento	Variante	Acurácia	Prec. macro	Rec. macro	F1 macro
Padronização	Sem padronização	0,6500	0,5844	0,5697	0,5706
	Com padronização	0,6750	0,6243	0,6133	0,6167
Distância	Euclidiana	0,6750	0,6243	0,6133	0,6167
	Manhattan	0,6550	0,6005	0,5926	0,5950
	Minkowski (p=3)	0,6700	0,6181	0,6076	0,6108
	Chebyshev	0,6500	0,5933	0,5850	0,5872
PCA (80 % da variância)	Sem PCA	0,6750	0,6243	0,6133	0,6167
	Com PCA (8 comp.)	0,6425	0,5810	0,5717	0,5734

Fonte: elaborado pelos autores.

4.5. Desempenho acadêmico: SVM

Kernel linear. Com $C \geq$0,1 as métricas de teste se estabilizam (Figura 5): acurácia de 71,0 %, precisão macro de 0,670, recall macro de 0,618 e F1 macro de 0,623; C=0,001 gera um modelo que prevê apenas a classe majoritária (F1 macro de 0,401). Escolheu-se C=0,1, o menor valor que atinge o desempenho máximo, por ser mais regularizado. O recall foi de 0,89 para "não aprovado" e de apenas 0,35 para "aprovado", com AUC-ROC de 0,726 e *average precision* de 0,565, acima da referência de 0,33 (proporção de aprovados). Assim, o modelo separa as classes melhor que o acaso, mas a acurácia de 71,0 % está apenas 4 p.p. acima da referência de 67 %.

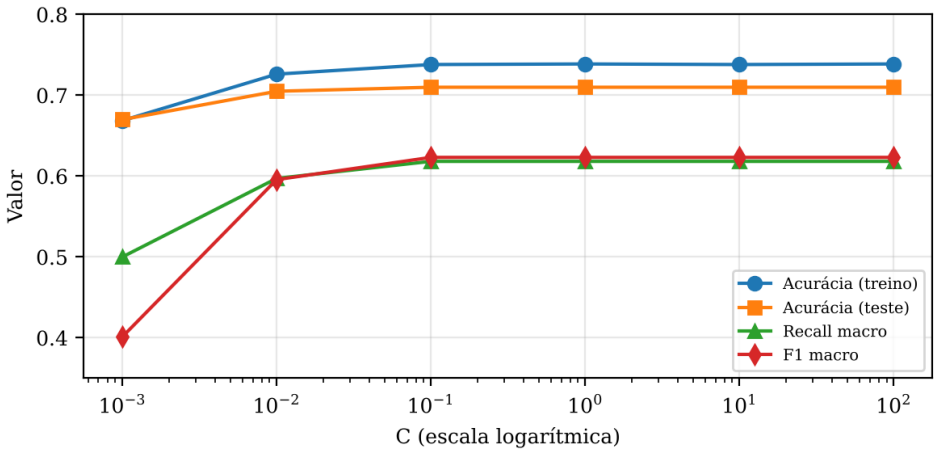


Figura 5. Desempenho acadêmico: SVM linear em função de C.
Fonte: elaborada pelos autores.

Kernel RBF. Das 25 combinações, 16 produziram acurácia de teste inferior ou igual a 67 % e recall da classe "aprovado" de no máximo 0,09 (Figura 6): são os casos de C baixo, que subajustam, e de $\gamma \geq$1, que sobreajustam. Com γ=1 ou 10 e $C \geq$1, a acurácia de treino foi

de 99,6 % a 100 %, com 1.598 a 1.600 vetores de suporte (quase todo o treino memorizado). A melhor combinação por F1 macro foi C=10 e γ=0,1 (F1 macro de 0,630, recall da classe "aprovado" de 0,45), mas sua acurácia de treino (87,8 %) é muito superior à de teste (68,5 %), indicando sobreajuste moderado. A segunda colocada (C=100 e γ=0,001) teve F1 de 0,630 com acurácia de treino de 74,0 % e de teste de 71,5 %, mais consistente.

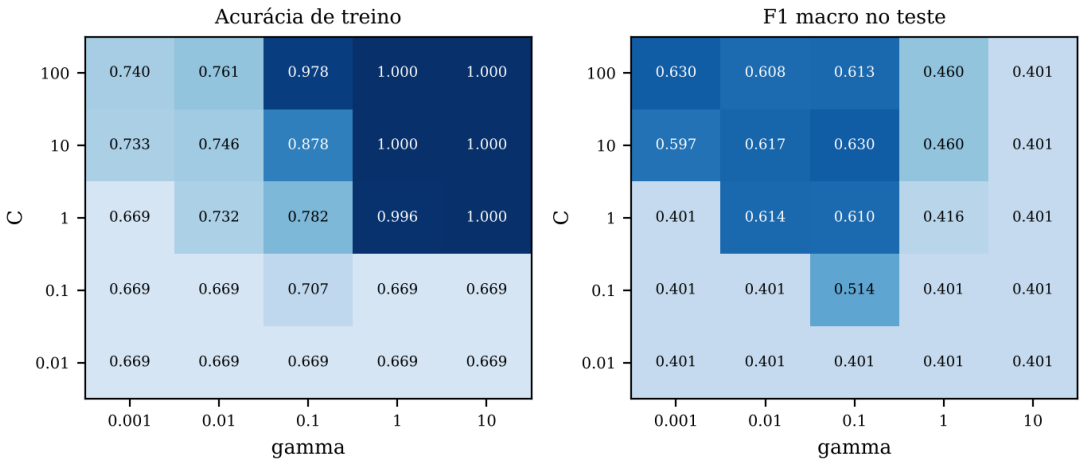


Figura 6. Desempenho acadêmico: acurácia de treino e F1 macro de teste do SVM RBF, por C e γ.
Fonte: elaborada pelos autores.

4.6. Desempenho acadêmico: comparação entre os modelos

A Tabela 6 reúne os melhores modelos. O SVM linear teve a maior acurácia, a maior precisão macro e a maior AUC; o RBF teve o maior F1 e o maior recall para "aprovado" dentre os SVM; e o *k*-NN teve o segundo maior recall para "aprovado" (0,43) com a menor acurácia. As métricas macro ficaram próximas (F1 entre 0,617 e 0,630). Com 400 exemplos de teste e seleção feita nele, essas diferenças não permitem apontar um vencedor. O SVM RBF não superou claramente o linear, o que é compatível com uma fronteira essencialmente linear entre aprovados e não aprovados neste conjunto, embora este estudo não tenha testado essa hipótese isoladamente. O ponto comum é a dificuldade em identificar os aprovados; o balanceamento das classes ou o ajuste do limiar de decisão são caminhos naturais, mas não foram testados.

Tabela 6. Desempenho acadêmico: melhores configurações no teste (400 alunos).

Modelo	Acur.	F1 macro	Rec. macro	Rec. aprov.	AUC	AP
Classe majoritária	0,670	–	0,500	0,000	–	–
k-NN (k=3, Eucl.)	0,675	0,617	0,613	0,43	–	–
SVM linear (C=0,1)	**0,710**	0,623	0,618	0,349	**0,726**	**0,565**
SVM RBF (C=10, γ=0,1)	0,685	**0,630**	**0,627**	**0,455**	0,680	0,507

Fonte: elaborado pelos autores. AUC e AP não foram calculados para o k-NN.

4.7. Limitações

Os resultados devem ser lidos com as seguintes ressalvas: (i) no problema acadêmico, os parâmetros foram escolhidos no próprio conjunto de teste, o que pode inflar as métricas; (ii) cada problema usa uma única divisão treino/teste de 400 registros, sem repetição, de modo que diferenças de até cerca de 2 a 4 p.p. estão dentro da variação amostral; (iii) no problema de entregas não foi avaliado o SVM linear, e k=51 é o limite superior da grade do k-NN; (iv) os conjuntos foram fornecidos pelo professor e não foi possível verificar aqui sua origem nem se refletem dados reais; e (v) não foram definidos custos para os tipos de erro, de modo que a escolha entre os modelos fica condicionada à aplicação.

5. CONCLUSÃO E TRABALHOS FUTUROS

Este trabalho comparou k-NN e SVM em dois problemas de classificação binária. No problema de entregas urbanas, com parâmetros escolhidos por validação cruzada no treino, os dois algoritmos tiveram desempenho praticamente igual no teste (82,25 % e 82,50 % de acurácia), com o SVM identificando mais atrasos (85,4 % contra 78,7 %) e o k-NN identificando mais entregas no prazo (85,6 % contra 79,8 %). No problema de desempenho acadêmico, os modelos ficaram pouco acima da referência da classe majoritária (acurácia de 67,5 % a 71,0 % contra 67 %) e tiveram dificuldade em reconhecer os alunos aprovados, de modo que os atributos disponíveis parecem conter informação limitada para essa previsão. Em ambos, o desempenho foi sensível aos hiperparâmetros: configurações extremas de C e γ degeneram para a previsão da classe majoritária ou sobreajustam, e a padronização dos atributos foi necessária.

Como trabalhos futuros, propõem-se: (i) repetir os experimentos acadêmicos com seleção de parâmetros por validação cruzada no treino, tornando-os comparáveis aos de entregas; (ii) usar validação cruzada repetida ou testes estatísticos para comparar os modelos; (iii) tratar o desbalanceamento da classe “aprovado” (pesos de classe, reamostragem e ajuste do

limiar); (iv) avaliar o SVM linear em entregas e valores de k acima de 51; (v) incluir outros classificadores, como árvores de decisão e *Random Forest*, como em Wessel (2026); e (vi) definir custos para cada tipo de erro, para guiar a escolha do modelo.

REFERÊNCIAS

AYRES, L. D. G.; BRITO, I. V. S.; SOUZA, R. R. G. e. **Utilizando aprendizado de máquina para detecção automática de URLs maliciosas brasileiras**. Salvador: Universidade Federal da Bahia, [2019?]. Artigo em PDF.

CORTES, C.; VAPNIK, V. Support-vector networks. **Machine Learning**, v. 20, n. 3, p. 273–297, 1995.

COVER, T.; HART, P. Nearest neighbor pattern classification. **IEEE Transactions on Information Theory**, v. 13, n. 1, p. 21–27, 1967.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

SILVA, L. A.; PERES, S. M.; BOSCARIOLI, C. **Introdução à mineração de dados**: com aplicações em R. Rio de Janeiro: Elsevier, 2016.

WESSEL, L. H. Aprendizado de máquina na predição de doença cardíaca: uma análise comparativa de algoritmos de classificação. **Revista Eletrônica Multidisciplinar de Investigação Científica**, v. 5, n. 23, p. 899–908, 2026. DOI: 10.47402/remici.v5n23696926.